Rapport des listes préliminaires de personnages Corpus Asimov de ALILI Lina

Université d'Avignon, Master 1 Infrastructures Cloud et Systèmes Distribués

02 Octobre 2026

1. Démarche générale

Nous suivons une stratégie générer puis filtrer : une liste L large (priorité au rappel), puis des heuristiques qui réduisent le bruit pour obtenir les personnages (LN) et les lieux (LL). Le pipeline Python comporte six scripts exécutés dans l'ordre :

nettoyage.py puis tokenisation.py puis ngrams.py puis liste_entites.py (L) puis liste_L_filtre.py, liste_LN.py (LN et LL)

Les statistiques du corpus (tokens, phrases, vocabulaire, hapax, taille de chaque liste) sont fournies dans statistiques.txt, produit par statistiques.py.

2. Prétraitement

Nettoyage. Le corpus ne contient que les pages impaires, extraites d'un PDF : mots coupés, mots collés , tirets de fin de ligne, numéros de page. Plutôt que des règles écrites mot par mot, un seul algorithme de segmentation par programmation dynamique cherche, pour chaque suite de fragments, le découpage de coût minimal. Le coût d'un mot combine la fréquence du français (wordfreq) et un lexique construit automatiquement sur le corpus : mots inconnus de wordfreq et noms propres, composés à tiret (eux-mêmes), et noms coupés par le PDF dont les morceaux reviennent toujours ensemble (Tr ev ize - Trevize). Garde-fous : deux mots français valides voisins ne sont jamais fusionnés, et un groupe n'est modifié que si le gain de score est net.

Tokenisation. Les tokens sont des suites de lettres Unicode, des nombres et des composés à tiret. Les élisions sont séparées (l' + homme) pour correspondre à l'antidictionnaire. La ponctuation n'est pas conservée comme token : elle sert à délimiter les phrases, marquées par FIN_PHRASE (coupure sur . ! ? suivie d'une majuscule, d'un guillemet ou d'un tiret de dialogue, hors abréviations comme M. ou Dr.). Les majuscules sont conservées : c'est le principal indice des noms propres.

3. N-grammes et liste L

Les uni-, bi- et trigrammes sont comptés par fichier, sans jamais traverser une fin de phrase, avec la casse conservée. Un n-gramme est candidat à la liste L si son premier et son dernier mot commencent par une majuscule et si les mots intermédiaires ont une majuscule ou sont une particule (de, du, la, et), avec une fréquence ≥ 2. Pour chaque candidat, on garde la fréquence, la répartition par livre et un ratio de majuscule : la part des occurrences d'un mot écrites avec majuscule.

4. Filtrage, personnages (LN) et lieux (LL)

Antidictionnaire. On écarte les candidats contenant un mot vide de la liste fournie (en traitant l', qu' et les composés), les acronymes, les nombres et les mots.

Personnages (LN): Pour chaque candidat, on mesure dans le corpus des indices de contexte : titre avant (docteur, Maire, Lord), verbe de parole ou de geste après (dit, répondit, sourit), préposition de lieu avant (sur, vers, dans, depuis). La préposition à est exclue car ambiguë (à Terminus / dit à Hardin). Un candidat est retenu comme personnage si : indices personne ≥ 10 % des occurrences, indice lieu < 20 %, présence au milieu d'une phrase ≥ 30 %, précédé d'un article dans moins de 50 %. On rejette aussi les impératifs à tiret (Pensez-vous) et les mots existant au singulier et au pluriel (gentilés). Les titres en tête sont retirés et les variantes regroupées avec le nombre de mentions.

Lieux (LL). Même méthode, depuis la liste L non filtrée (pour garder les noms avec particule) : indice de lieu ≥ 20 % et supérieur à l'indice personnel.

5. Choix justifiés

- **N-grammes et heuristiques plutôt qu'un tagueur (Freeling, spaCy)** : Un tagueur est un programme déjà entraîné qui repère tout seul les noms propres. J’ai préféré écrire mes propres règles, pour trois raisons : nous comprenons et pouvons régler chaque décision ; un tagueur connaît mal les noms inventés (Trevize, Gendibal) et notre texte est incomplet (pages impaires). Un tagueur pourrait servir plus tard à vérifier mes résultats.
- **Majuscules conservées et ponctuation :** utilisée pour délimiter les phrases avant d'être retirée : indispensable pour distinguer un nom propre d'un début de phrase.
- **Rappel d'abord (L), précision ensuite (LN, LL)**, avec des seuils réglés empiriquement en inspectant les résultats.